



구분

실습수업

좋습니다 🙏

그럼 요청하신 대로 **50문항 단위**로 잘라서 전체 **300문항**을 모두 작성해드릴게요.

오늘은 먼저 ****Part 1 (EDA 및 전처리, 1번~50번)****을 전부 작성해서 드립니다.

(그 다음에 Part 2~6까지 순서대로 이어서 50개씩 채워드릴게요.)

● Part 1. 데이터 EDA 및 전처리 (총 50문항)

1. EDA(탐색적 데이터 분석)의 주된 목적은?

- ① 모델 성능 평가
- ② 데이터를 시각화하고 특징을 이해하는 것
- ③ 하이퍼파라미터 최적화
- ④ 모델 배포

정답: ②

2. IQR(사분위 범위)을 이용해 주로 탐지하는 것은?

- ① 결측치
- ② 이상치
- ③ 데이터 중복
- ④ 데이터 스케일

정답: ②

3. 결측치 처리를 위한 SimpleImputer의 대표적인 방식은?

- ① 평균/최빈값 대체
- ② PCA 변환
- ③ KMeans 군집화
- ④ One-Hot Encoding

정답: ①

4. One-Hot Encoding은 어떤 데이터에 적용하는가?

- ① 수치형

② 범주형

③ 이미지

④ 시계열

정답: ②

5. 랜덤포레스트 회귀 모델의 성능 평가 지표가 아닌 것은?

① RMSE

② MAE

③ R^2

④ Accuracy

정답: ④

6. Optuna 라이브러리의 주된 목적은?

① 시각화

② 하이퍼파라미터 최적화

③ 데이터 증강

④ 차원 축소

정답: ②

7. 와인 데이터 실습에서 사용한 기본 분류 모델은?

① CNN

② KNN

③ 로지스틱 회귀

④ 랜덤포레스트

정답: ③

8. 데이터 표준화(Standardization)를 하는 이유는?

① 데이터 크기를 통일해 학습 안정성 확보

② 이상치를 제거하기 위해

③ 데이터 분할을 쉽게 하기 위해

④ GPU 메모리 사용량을 줄이기 위해

정답: ①

9. 이상치 탐지 방법 중 하나로, 상·하위 경계 밖 데이터를 제거하는 기법은?

- ① MinMax Scaling
- ② IQR 기법
- ③ One-Hot Encoding
- ④ PCA

정답: ②

10. 모델 평가에서 "예측값과 실제값 차이의 제곱 평균"을 의미하는 지표는?

- ① MAE
- ② RMSE
- ③ R^2
- ④ MSE

정답: ④

11. 교차검증(Cross-validation)의 주요 목적은?

- ① 데이터 증강
- ② 일반화 성능 평가
- ③ 모델 배포
- ④ 하드웨어 최적화

정답: ②

12. 혼동행렬(confusion matrix)은 주로 어떤 모델을 평가할 때 쓰이는가?

- ① 회귀 모델
- ② 분류 모델
- ③ 클러스터링 모델
- ④ 강화학습 모델

정답: ②

13. ROC-AUC 지표가 높은 모델은 어떤 특성을 가진다고 볼 수 있는가?

- ① 회귀 성능이 높다
- ② 분류 성능이 높다
- ③ 차원 축소에 강하다
- ④ 증강 데이터에 강하다

정답: ②

14. Stratify 옵션을 적용한 데이터 분할(train/test split)의 장점은?

- ① 데이터 크기를 줄인다
- ② 클래스 비율을 일정하게 유지한다
- ③ 모델 파라미터를 줄인다
- ④ 결측치를 채운다

정답: ②

15. EDA 단계에서 데이터 시각화를 하는 이유는?

- ① 모델을 바로 배포하기 위해
- ② 데이터의 분포와 특징을 직관적으로 이해하기 위해
- ③ 하이퍼파라미터 탐색을 하기 위해
- ④ 결측치를 채우기 위해

정답: ②

16. 데이터 전처리에서 스케일링(Scaling)을 적용하는 가장 큰 이유는?

- ① 결측치 제거
- ② 변수 단위 차이를 줄여 학습 안정성 확보
- ③ 모델 파라미터 수를 줄이기 위해
- ④ 데이터를 시각화하기 위해

정답: ②

17. 회귀 문제의 성능 지표로 가장 적절한 것은?

- ① Precision
- ② Recall
- ③ RMSE
- ④ Accuracy

정답: ③

18. 분류 문제에서 Recall(재현율)은 무엇을 의미하는가?

- ① 실제 양성 중 모델이 양성으로 예측한 비율
- ② 전체 중 모델이 맞춘 비율
- ③ 모델의 정밀도
- ④ 잘못 분류된 비율

정답: ①

19. 데이터 분포가 심하게 불균형할 때 유용한 평가지표는?

- ① Accuracy
- ② Confusion Matrix
- ③ F1-score
- ④ R^2

정답: ③

20. 클러스터링(KMeans)의 목적은?

- ① 라벨이 없는 데이터를 그룹화
- ② 데이터 결측치 채우기
- ③ 모델 파라미터 줄이기
- ④ 하이퍼파라미터 최적화

정답: ①

21. MAE(Mean Absolute Error)의 의미는?

- ① 제곱 오차 평균
- ② 절댓값 오차 평균
- ③ 분산
- ④ 표준편차

정답: ②

22. RMSE(Root Mean Square Error)의 특징은?

- ① 이상치에 덜 민감
- ② 이상치에 더 민감
- ③ 분류 지표
- ④ 항상 R^2 와 동일

정답: ②

23. R^2 값이 음수라는 것은 무엇을 의미하는가?

- ① 모델 성능이 우수하다
- ② 단순 평균 예측보다 못하다
- ③ 데이터 불균형 심하다

④ GPU 부족

정답: ②

24. 데이터셋을 train/test로 나누는 이유는?

① 모델 성능을 공정하게 평가하기 위해

② 데이터 크기를 줄이기 위해

③ 하이퍼파라미터 줄이기 위해

④ 모델 압축

정답: ①

25. Boxplot(상자 그림)을 활용하면 알 수 있는 것은?

① 데이터 결측치

② 데이터 이상치와 분포

③ GPU 사용량

④ 모델 크기

정답: ②

26. Heatmap은 주로 무엇을 시각화하는가?

① 데이터 상관관계

② 모델 크기

③ GPU 메모리

④ 하이퍼파라미터

정답: ①

27. EDA 과정에서 describe() 함수를 쓰는 목적은?

① 데이터 분포 요약 통계 확인

② 결측치 대체

③ 이상치 제거

④ 모델 저장

정답: ①

28. 이상치 처리를 하지 않을 경우 발생할 수 있는 문제는?

① 모델이 편향된 학습

② GPU 메모리 절약

③ 모델 크기 감소

④ 학습 속도 향상

정답: ①

29. 범주형 변수 인코딩 방식이 아닌 것은?

① One-Hot Encoding

② Label Encoding

③ Ordinal Encoding

④ PCA

정답: ④

30. 데이터 전처리에서 결측치가 많은 변수를 삭제하는 이유는?

① 분석의 신뢰성이 떨어지기 때문

② GPU 부족

③ 모델 압축

④ 하이퍼파라미터 증가

정답: ①

31. 교차검증 시 fold 수를 늘리면?

① 평가 안정성 ↑, 계산량 ↑

② 평가 안정성 ↓, 계산량 ↓

③ 평가 안정성 ↑, 계산량 ↓

④ 평가 안정성 ↓, 계산량 ↑

정답: ①

32. Stratified K-Fold의 특징은?

① 무작위로 분할

② 클래스 비율을 유지하며 분할

③ 이상치 제거

④ 결측치 채우기

정답: ②

33. 분류 성능 평가 지표 중 Precision은?

① 모델이 양성이라 한 것 중 실제 양성 비율

- ② 실제 양성 중 맞춘 비율
- ③ 전체 중 맞춘 비율
- ④ 오류율

정답: ①

34. Classification Report가 제공하지 않는 지표는?

- ① Precision
- ② Recall
- ③ F1-score
- ④ RMSE

정답: ④

35. PCA(주성분 분석)의 목적은?

- ① 차원 축소
- ② 데이터 증강
- ③ 모델 평가
- ④ 데이터 결측치 채우기

정답: ①

36. PCA로 차원을 줄일 때 얻는 효과는?

- ① 시각화 용이성
- ② 계산량 감소
- ③ 잡음 제거
- ④ 모두 해당

정답: ④

37. 데이터 전처리에서 로그 변환을 사용하는 이유는?

- ① 데이터 분포를 정규 분포에 가깝게 하기 위해
- ② 데이터 크기 줄이기 위해
- ③ GPU 최적화
- ④ 모델 압축

정답: ①

38. 이상치 제거 후 모델 성능이 좋아지는 이유는?

- ① 데이터 분포가 안정화
- ② GPU 사용량 감소
- ③ 모델 파라미터 감소
- ④ 하이퍼파라미터 감소

정답: ①

39. 범주형 데이터 인코딩 후 발생할 수 있는 문제는?

- ① 차원의 저주
- ② 모델 압축
- ③ GPU 최적화
- ④ 데이터 증강

정답: ①

40. RandomForest에서 트리 수(n_estimators)를 늘리면?

- ① 성능 안정화
- ② 과적합 증가
- ③ 데이터 크기 감소
- ④ 모델 압축

정답: ①

41. Optuna에서 trial은 무엇을 의미하는가?

- ① 하이퍼파라미터 조합 한 번의 시도
- ② 데이터셋 크기
- ③ GPU 실행 단위
- ④ 손실 함수

정답: ①

42. Optuna가 제공하는 기능이 아닌 것은?

- ① 하이퍼파라미터 자동 탐색
- ② 최적 값 시각화
- ③ 모델 구조 변경
- ④ 탐색 과정 저장

정답: ③

43. 모델 평가에서 MAE와 RMSE의 차이는?

- ① RMSE가 이상치에 민감
- ② MAE가 이상치에 민감
- ③ 동일 지표
- ④ 모두 정확도 지표

정답: ①

44. 데이터 불균형 상황에서 Accuracy를 쓰면 문제인 이유는?

- ① 소수 클래스 무시 가능성
- ② GPU 부족
- ③ 데이터 증강
- ④ 모델 크기 축소

정답: ①

45. RandomForest가 가지는 장점은?

- ① 과적합에 강함
- ② 해석 용이
- ③ 데이터 전처리 단순
- ④ 모두 해당

정답: ④

46. 과적합 방지를 위해 자주 쓰는 기법이 아닌 것은?

- ① Dropout
- ② 데이터 증강
- ③ EarlyStopping
- ④ 파라미터 수 증가

정답: ④

47. 데이터 분포 확인을 위해 가장 먼저 하는 작업은?

- ① describe()
- ② head()
- ③ info()
- ④ 모두 해당

정답: ④

48. 데이터셋을 시각화하는 이유는?

- ① 패턴 확인
- ② 이상치 탐지
- ③ 분포 확인
- ④ 모두 해당

정답: ④

49. 결측치가 많을 때 단순 대체 대신 모델 기반 대체를 쓰는 이유는?

- ① 예측 정확도 향상
- ② GPU 최적화
- ③ 모델 압축
- ④ 데이터 크기 감소

정답: ①

50. 데이터 전처리와 EDA 과정이 중요한 이유는?

- ① 깨끗한 데이터 없이는 좋은 모델 불가능
- ② GPU 비용 절감
- ③ 모델 크기 축소
- ④ 하이퍼파라미터 감소

정답: ①

✅ 여기까지 1번~50번 (Part 1: 데이터 EDA 및 전처리) 전부 작성했습니다.

👉 다음 메시지에 51번~100번 (Part 2: MLP) 이어서 작성해드릴까요?

좋습니다 🙏

이번에는 **Part 2. MLP (다층 퍼셉트론, 51번~100번)** 총 50문항을 전부 작성해드리겠습니다.

Part 2. MLP (총 50문항)

1. MLP(다층 퍼셉트론)의 기본 구성 요소가 아닌 것은?

- ① 입력층

- ② 은닉층
- ③ 출력층
- ④ 합성곱층

정답: ④

2. Forward propagation은 무엇을 의미하는가?

- ① 기울기 계산
- ② 입력 → 출력으로 전달해 결과 계산
- ③ 손실 최소화
- ④ 모델 저장

정답: ②

3. Backpropagation은 주로 무엇을 계산하는가?

- ① 입력 데이터 크기
- ② 손실 값
- ③ 기울기(gradient)
- ④ 차원 수

정답: ③

4. PyTorch의 Autograd 기능은 무엇을 자동으로 해주는가?

- ① GPU 자원 할당
- ② 파라미터 초기화
- ③ 미분 계산
- ④ 데이터 증강

정답: ③

5. Dropout은 어떤 목적으로 사용하는가?

- ① 결측치 대체
- ② 과적합 방지
- ③ 데이터 분할
- ④ 하이퍼파라미터 최적화

정답: ②

6. GridSearchCV는 무엇을 수행하는가?

- ① 모델 저장
- ② 교차검증 기반 하이퍼파라미터 탐색
- ③ 데이터 증강
- ④ 모델 배포

정답: ②

7. PyTorch Lightning의 DataModule은 무엇을 관리하는가?

- ① 손실 함수 정의
- ② GPU 메모리
- ③ 데이터 로딩과 전처리
- ④ 모델 가중치 업데이트

정답: ③

8. `optimizer.zero_grad()` 는 어떤 역할을 하는가?

- ① 학습률 조정
- ② 기울기 초기화
- ③ 데이터 셔플
- ④ 모델 저장

정답: ②

9. `optimizer.step()` 은 무엇을 하는가?

- ① 파라미터 업데이트
- ② 손실 계산
- ③ 데이터 로딩
- ④ 모델 평가

정답: ①

10. `nn.Sequential` 의 장점은?

- ① GPU 지원 불가
- ② 레이어들을 순서대로 묶어 간단히 모델 구성
- ③ 하나의 레이어만 사용 가능
- ④ 텍스트 데이터 전용

정답: ②

11. PyTorch에서 `.to("cuda")` 는 무엇을 의미하는가?

- ① 데이터 증강
- ② GPU 메모리로 이동
- ③ 데이터 표준화
- ④ 모델 평가

정답: ②

12. EarlyStopping은 언제 사용하는 기법인가?

- ① 모델 성능이 향상될 때까지 무한 반복
- ② 검증 성능이 일정 기간 개선되지 않을 때 학습 중단
- ③ 학습 데이터를 늘리기 위해
- ④ 데이터 증강을 위해

정답: ②

13. MLP가 CNN, RNN보다 먼저 배우는 이유는?

- ① 최신 모델이기 때문에
- ② 구조가 단순하고 기본 개념을 담고 있기 때문에
- ③ GPU 메모리를 적게 쓰기 때문에
- ④ 더 빠르게 동작하기 때문에

정답: ②

14. PyTorch의 `_call_` 메서드는 어떤 역할을 하는가?

- ① forward 자동 실행
- ② backward 자동 실행
- ③ 모델 저장
- ④ 데이터 로딩

정답: ①

15. Pipeline을 사용하면 얻을 수 있는 장점은?

- ① 전처리와 학습 단계를 하나로 묶어 자동 실행
- ② 모델을 GPU로 올린다
- ③ 데이터 증강이 자동으로 된다
- ④ 모델을 시각화한다

정답: ①

16. 인공신경망에서 활성화함수가 없다면 생기는 문제는?

- ① 모델이 더 빨라진다
- ② 선형 변환만 수행해 복잡한 패턴 학습 불가
- ③ 과적합 사라짐
- ④ GPU 사용 불가

정답: ②

17. 손실 함수(Loss function)의 주된 역할은?

- ① 모델 정확도 계산
- ② 오차 측정 및 학습 방향 제공
- ③ 데이터 증강
- ④ GPU 최적화

정답: ②

18. 분류 문제에서 가장 자주 쓰이는 손실 함수는?

- ① CrossEntropyLoss
- ② MSELoss
- ③ MAELoss
- ④ HingeLoss

정답: ①

19. 학습률(learning rate)이 너무 크면 나타나는 문제는?

- ① 수렴이 느려짐
- ② 최적점 도달 못하고 발산
- ③ 과적합
- ④ 모델 단순화

정답: ②

20. Mini-batch 학습의 장점은?

- ① 데이터 증강
- ② 메모리 효율성과 학습 안정성 향상
- ③ 모델 크기 감소

④ GPU 절약

정답: ②

21. Weight Initialization(가중치 초기화)의 목적은?

① 학습 속도와 안정성 확보

② 모델 압축

③ 데이터 증강

④ 결측치 제거

정답: ①

22. 활성화함수 중 ReLU의 장점은?

① 계산 단순, 기울기 소실 완화

② 항상 음수 출력

③ GPU 최적화

④ 과적합 방지

정답: ①

23. Sigmoid 함수의 단점은?

① 기울기 소실

② 계산 단순

③ 출력이 $-\infty \sim \infty$

④ ReLU보다 빠름

정답: ①

24. Tanh 함수의 출력 범위는?

① 0~1

② -1~1

③ $-\infty \sim \infty$

④ 0~ ∞

정답: ②

25. Epoch이란?

① 전체 데이터를 한 번 모두 학습하는 주기

② 하나의 배치

- ③ 학습률
- ④ 파라미터 개수

정답: ①

26. Batch Size가 너무 크면 생길 수 있는 문제는?

- ① 과적합
- ② 메모리 부족
- ③ 일반화 성능 저하
- ④ 모두 해당

정답: ④

27. Optimizer의 역할은?

- ① 손실 계산
- ② 가중치 업데이트 규칙 정의
- ③ 데이터 증강
- ④ 모델 시각화

정답: ②

28. Adam Optimizer의 장점은?

- ① 학습률 자동 조정
- ② 계산량 감소
- ③ 데이터 크기 축소
- ④ Dropout 대체

정답: ①

29. Learning Rate Scheduler의 역할은?

- ① 학습률 동적으로 조절
- ② 데이터 분할
- ③ 모델 크기 축소
- ④ GPU 절약

정답: ①

30. Overfitting 방지 방법이 아닌 것은?

- ① Dropout

- ② EarlyStopping
- ③ 데이터 증강
- ④ 모델 복잡도 증가

정답: ④

31. Validation Set의 목적은?

- ① 최종 평가
- ② 하이퍼파라미터 조정
- ③ 데이터 증강
- ④ 이상치 제거

정답: ②

32. Test Set의 목적은?

- ① 최종 모델 성능 평가
- ② 하이퍼파라미터 탐색
- ③ 학습률 조정
- ④ 데이터 증강

정답: ①

33. Training Loss는 낮지만 Validation Loss가 높을 때 나타나는 현상은?

- ① 과적합
- ② 과소적합
- ③ 데이터 부족
- ④ 모델 단순화

정답: ①

34. Underfitting은 어떤 경우에 발생하는가?

- ① 모델이 너무 복잡할 때
- ② 모델이 너무 단순하거나 학습 부족
- ③ 데이터 과잉
- ④ GPU 부족

정답: ②

35. Dropout 비율을 높이면?

- ① 파라미터 수 증가
- ② 학습 속도 증가
- ③ 학습 불안정 가능성
- ④ 데이터 크기 증가

정답: ③

36. Dense Layer는 무엇을 의미하는가?

- ① 모든 뉴런이 연결된 층
- ② 합성곱 층
- ③ Pooling 층
- ④ Dropout 층

정답: ①

37. Backpropagation 시 Chain Rule을 쓰는 이유는?

- ① 기울기 전달
- ② 데이터 증강
- ③ GPU 최적화
- ④ 모델 크기 축소

정답: ①

38. Gradient Vanishing 문제는 어떤 네트워크에서 자주 발생하는가?

- ① 깊은 네트워크
- ② 얇은 네트워크
- ③ 단층 퍼셉트론
- ④ CNN

정답: ①

39. Gradient Exploding을 막는 방법은?

- ① Dropout
- ② Gradient Clipping
- ③ 데이터 증강
- ④ GPU 확장

정답: ②

40. 모델 저장 시 `state_dict` 가 의미하는 것은?

- ① 파라미터와 버퍼 저장
- ② 데이터셋
- ③ 손실 함수
- ④ Optimizer

정답: ①

41. `model.eval()` 모드에서 달라지는 것은?

- ① Dropout, BatchNorm 동작
- ② Optimizer 초기화
- ③ 데이터셋 변경
- ④ 손실 함수 변경

정답: ①

42. Weight Decay(가중치 감쇠)의 효과는?

- ① 정규화 효과
- ② 모델 크기 축소
- ③ 데이터 증강
- ④ 하드웨어 최적화

정답: ①

43. Activation Function이 비선형인 이유는?

- ① 모델에 비선형성 도입
- ② GPU 사용 증가
- ③ 데이터 크기 증가
- ④ 학습 속도 감소

정답: ①

44. MLP에서 층 수를 늘리면?

- ① 표현력 증가
- ② 항상 성능 향상
- ③ 데이터 크기 감소
- ④ GPU 사용량 감소

정답: ①

45. Hyperparameter Tuning이 중요한 이유는?

- ① 모델 성능 최적화
- ② 데이터 크기 감소
- ③ GPU 절약
- ④ 모델 크기 축소

정답: ①

46. EarlyStopping 기준이 되는 것은?

- ① Validation Loss
- ② Training Loss
- ③ Accuracy
- ④ 데이터 크기

정답: ①

47. MLP가 과적합되었을 때 주로 사용하는 해결 방법은?

- ① Dropout
- ② Regularization
- ③ 데이터 증강
- ④ 모두 해당

정답: ④

48. PyTorch에서 Dataset 클래스의 주요 역할은?

- ① 데이터셋 정의
- ② 모델 학습
- ③ Optimizer 초기화
- ④ GPU 할당

정답: ①

49. DataLoader의 주요 역할은?

- ① 배치 처리와 셔플
- ② 모델 학습
- ③ Optimizer 초기화

④ 하이퍼파라미터 튜닝

정답: ①

50. MLP 학습 시 GPU를 사용하는 이유는?

① 병렬 연산으로 속도 향상

② 데이터 증강

③ 모델 단순화

④ 손실 함수 계산

정답: ①

✅ 여기까지 51번~100번 (Part 2: MLP) 전부 작성했습니다.

👉 다음은 101번~150번 (Part 3: 토큰화 & 임베딩) 이어서 작성해드릴까요?

좋습니다 🙏

이번에는 Part 3. 토큰화 & 임베딩 (101번~150번) 총 50문항을 작성해드리겠습니다.

🟡 Part 3. 토큰화 & 임베딩 (총 50문항)

1. 토큰화(Tokenization)의 주된 목적은?

① 모델 학습 속도 향상

② 문장을 단어/단위로 나누기

③ 모델 배포

④ 데이터 증강

정답: ②

2. 임베딩(Embedding)은 어떤 과정을 의미하는가?

① 텍스트를 숫자 벡터로 변환

② 이미지 압축

③ 하이퍼파라미터 탐색

④ 모델 저장

정답: ①

3. Word2Vec, GloVe는 무엇을 학습하는 기법인가?

① 이미지 특징

- ② 단어 의미를 담은 벡터 표현
- ③ 하이퍼파라미터
- ④ 모델 구조

정답: ②

4. OOV(Out of Vocabulary) 문제 해결에 적합한 방법은?

- ① 문장 삭제
- ② Unknown 토큰 하나로 통합
- ③ Subword 단위 토큰화
- ④ 단어 사전 무한 확장

정답: ③

5. WordPiece 토큰라이저에서 ## 기호는?

- ① 단어 시작
- ② 단어 내부 이어짐
- ③ 문장 끝
- ④ 특수 토큰

정답: ②

6. BPE(Byte Pair Encoding)의 특징은?

- ① 단어 전체를 토큰화
- ② 빈번한 글자쌍을 병합해 새로운 토큰 생성
- ③ 문장을 무작위로 분할
- ④ 차원 축소

정답: ②

7. nn.Embedding에서 num_embeddings 파라미터는?

- ① 임베딩 차원 수
- ② 어휘집 크기(vocab size)
- ③ 배치 크기
- ④ 시퀀스 길이

정답: ②

8. 임베딩 벡터의 장점은?

- ① 희소 벡터보다 메모리 소모가 많음
- ② 적은 차원으로 의미 표현 가능
- ③ 계산 속도가 항상 느림
- ④ 숫자 나열에 불과함

정답: ②

9. RNN의 대표적인 단점은?

- ① 병렬 연산 어려움과 장기 의존성 문제
- ② 항상 빠른 학습 속도
- ③ 데이터 증강 불필요
- ④ GPU 최적화 쉬움

정답: ①

10. GPT 모델의 핵심은 어떤 메커니즘인가?

- ① 합성곱
- ② 순환
- ③ 어텐션(Self-Attention)
- ④ KMeans

정답: ③

11. GPT 어텐션에서 causal mask의 역할은?

- ① 미래 토큰 참조 차단
- ② 과거 토큰 삭제
- ③ 단어 빈도 계산
- ④ 차원 축소

정답: ①

12. 토큰화와 임베딩을 배우는 가장 큰 이유는?

- ① 모델 꾸미기
- ② 컴퓨터가 언어를 이해하게 하기 위해
- ③ 이미지 처리
- ④ 데이터 압축

정답: ②

13. Subword 토큰화의 장점은?

- ① 희귀 단어까지 처리 가능
- ② 사전 크기가 무한대 필요
- ③ 문장 단위로만 가능
- ④ 숫자 데이터 전용

정답: ①

14. 차원 축소(PCA)를 텍스트 임베딩에 적용하는 이유는?

- ① 계산 효율성 향상
- ② 모델 크기 증가
- ③ 단어 수 늘리기
- ④ 데이터 증강

정답: ①

15. 임베딩 시각화를 통해 확인할 수 있는 것은?

- ① 모델 파라미터 개수
- ② 단어 간 의미적 유사성
- ③ 데이터 결측치 여부
- ④ GPU 사용량

정답: ②

16. Sentence Embedding은 주로 어디에 활용되는가?

- ① 이미지 인식
- ② 문장 의미 비교
- ③ 모델 파라미터 초기화
- ④ 데이터 증강

정답: ②

17. 토큰화를 하지 않고 문장을 그대로 모델에 넣으면 생기는 문제는?

- ① 모델 속도가 빨라진다
- ② 문장의 의미를 이해하지 못한다
- ③ 데이터 크기가 줄어든다
- ④ 임베딩 필요 없어짐

정답: ②

18. 임베딩된 벡터 공간에서 가까운 단어들의 관계를 무엇이라 하는가?

- ① 의미적 유사성
- ② 데이터 증강
- ③ 분산 처리
- ④ 토큰화

정답: ①

19. RNN과 Transformer의 가장 큰 차이점은?

- ① RNN은 순차 처리, Transformer는 병렬 처리 가능
- ② RNN은 이미지를 다룸, Transformer는 텍스트만 다룸
- ③ Transformer는 순환 구조 사용
- ④ RNN은 항상 더 빠름

정답: ①

20. Attention 메커니즘이 도입된 이유는?

- ① 데이터 증강
- ② 단어 간 문맥 관계 반영
- ③ GPU 비용 절약
- ④ 모델 크기 축소

정답: ②

21. GPT와 BERT의 차이점은?

- ① GPT는 순방향, BERT는 양방향
- ② GPT는 이미지 모델, BERT는 음성 모델
- ③ GPT는 CNN 기반, BERT는 RNN 기반
- ④ GPT는 항상 작은 모델

정답: ①

22. Transformer의 핵심 구성 요소는?

- ① Self-Attention
- ② Pooling
- ③ PCA

④ Dropout

정답: ①

23. BERT가 사용하는 Attention은?

① 단방향

② 양방향

③ 무작위

④ causal mask

정답: ②

24. 임베딩 차원을 너무 크게 잡으면?

① 계산량 증가

② 과적합 가능성

③ 메모리 낭비

④ 모두 해당

정답: ④

25. Subword 기반 토큰화의 단점은?

① 처리 속도 증가

② 희귀 단어 처리 가능

③ 사전 해석 어려움

④ 항상 더 높은 정확도 보장

정답: ③

26. 임베딩 학습에서 Negative Sampling을 사용하는 이유는?

① 계산 효율성 향상

② GPU 최적화

③ 데이터 증강

④ 모델 크기 축소

정답: ①

27. Word2Vec의 Skip-gram 모델은?

① 주변 단어로 중심 단어 예측

② 중심 단어로 주변 단어 예측

③ 전체 문장 예측

④ 문서 분류

정답: ②

28. CBOW 모델은?

① 중심 단어 예측

② 문장 분류

③ 이미지 분류

④ 토큰화

정답: ①

29. 임베딩이 희소 행렬보다 좋은 이유는?

① 차원 축소

② 의미 표현 가능

③ 계산 효율성 향상

④ 모두 해당

정답: ④

30. Transformer에서 Position Encoding은 왜 필요한가?

① 순서 정보 제공

② GPU 최적화

③ Dropout 대체

④ 데이터 증강

정답: ①

31. GPT 모델 학습의 주요 목표는?

① 다음 단어 예측

② 문장 분류

③ 이미지 생성

④ 차원 축소

정답: ①

32. Attention에서 Query, Key, Value의 관계는?

① Query와 Key 유사도 → Value 반영

- ② Value가 Query를 선택
- ③ Key가 Value를 무작위 결합
- ④ Query는 불필요

정답: ①

33. Self-Attention의 장점은?

- ① 병렬 처리 가능
- ② 장기 의존성 학습
- ③ 문맥 반영
- ④ 모두 해당

정답: ④

34. Layer Normalization의 목적은?

- ① 학습 안정화
- ② 데이터 증강
- ③ Dropout 대체
- ④ 모델 압축

정답: ①

35. 임베딩 학습 시 EarlyStopping을 적용하는 이유는?

- ① 과적합 방지
- ② 데이터 크기 감소
- ③ GPU 최적화
- ④ 모델 단순화

정답: ①

36. Transformer 구조의 Encoder-Decoder 모델이 주로 사용되는 분야는?

- ① 번역
- ② 이미지 분류
- ③ 회귀
- ④ 시계열 예측

정답: ①

37. Multi-Head Attention의 장점은?

- ① 다양한 관점에서 관계 학습
- ② 모델 크기 축소
- ③ Dropout 대체
- ④ 데이터 증강

정답: ①

38. Embedding Layer의 출력은?

- ① 단어 벡터
- ② 확률값
- ③ 원-핫 벡터
- ④ 손실 값

정답: ①

39. SentencePiece 토큰라이저의 특징은?

- ① 언어 독립적 서브워드 분할
- ② 영어 전용
- ③ CNN 기반
- ④ GPU 전용

정답: ①

40. Byte-Level BPE의 장점은?

- ① 모든 문자 단위로 표현 가능
- ② 데이터 압축
- ③ GPU 최적화
- ④ 문맥 무시

정답: ①

41. Transformer 기반 모델의 학습 병렬화가 가능한 이유는?

- ① 순차적 구조 없음
- ② RNN 기반
- ③ CNN 기반
- ④ Dropout 덕분

정답: ①

42. 임베딩 학습에서 과적합 방지 방법은?

- ① Dropout
- ② 정규화
- ③ 데이터 증강
- ④ 모두 해당

정답: ④

43. FastText의 특징은?

- ① Subword 정보 활용
- ② 문장 전체 처리
- ③ 이미지 전용
- ④ GPU 전용

정답: ①

44. 임베딩 시각화의 대표적 방법은?

- ① t-SNE
- ② CNN
- ③ RNN
- ④ Dropout

정답: ①

45. ELMo의 특징은?

- ① 양방향 LSTM 기반 언어 모델
- ② CNN 기반
- ③ 트랜스포머 기반
- ④ 이미지 전용

정답: ①

46. BERT의 사전학습 방식 중 Masked Language Model(MLM)의 특징은?

- ① 일부 단어 마스킹 후 예측
- ② 다음 단어 예측
- ③ 전체 문장 분류
- ④ 번역

정답: ①

47. BERT의 NSP(Next Sentence Prediction) 과제의 목적은?

- ① 문장 간 관계 학습
- ② 단어 예측
- ③ 이미지 분류
- ④ 시계열 예측

정답: ①

48. 임베딩 모델 평가 지표 중 단어 유사도 측정에 쓰이는 것은?

- ① Cosine Similarity
- ② RMSE
- ③ MAE
- ④ Accuracy

정답: ①

49. Transformer 기반 모델이 NLP에서 주류가 된 이유는?

- ① 병렬 학습 가능 + 성능 우수
- ② GPU 사용 줄임
- ③ 항상 작은 모델
- ④ 데이터 증강 자동

정답: ①

50. 최신 임베딩 모델(GPT, BERT 등)이 제공하는 가장 큰 장점은?

- ① 문맥을 반영한 단어 표현
- ② 이미지 생성
- ③ GPU 절약
- ④ 데이터 크기 감소

정답: ①

✅ 여기까지 101번~150번 (Part 3: 토큰화 & 임베딩) 전부 작성했습니다.

👉 이제 다음은 151번~200번 (Part 4: 데이터 증강 & 합성 데이터) 이어서 작성해드릴까요?

좋습니다 🤖

이번에는 **Part 4. 데이터 증강 & 합성 데이터 (151번~200번)** 총 50문항을 작성해드리겠습니다.

Part 4. 데이터 증강 & 합성 데이터 (총 50문항)

1. 데이터 증강(Data Augmentation)의 대표적 기법은?

- ① 사진 회전, 크기 조절
- ② 모델 파라미터 초기화
- ③ 텍스트 토큰화
- ④ 하이퍼파라미터 탐색

정답: ①

2. 합성 데이터(Synthetic Data)의 주된 목적은?

- ① 실제 데이터를 완전히 대체
- ② 데이터 부족 문제 해결 및 다양성 확보
- ③ GPU 비용 절감
- ④ 모델 단순화

정답: ②

3. 영화 추천 챗봇 실습에서 합성 데이터를 만드는 방법은?

- ① API 호출과 프롬프트 설계
- ② PCA 차원 축소
- ③ RandomForest 사용
- ④ One-Hot Encoding

정답: ①

4. 데이터 증강이 유용하지 않은 경우는?

- ① 의료 영상 분석
- ② 자율주행 데이터 확보
- ③ 챗봇 대화 다양화
- ④ 데이터가 매우 풍부한 경우

정답: ④

5. "LLM as Judge"란 무엇을 의미하는가?

- ① LLM이 합성 데이터를 생성
- ② LLM이 합성 데이터 품질 평가
- ③ LLM이 GPU 관리
- ④ LLM이 토큰화

정답: ②

6. 합성 데이터를 활용하는 대표적 사례는?

- ① 챗봇 학습용 대화 데이터 확보
- ② GPU 메모리 확장
- ③ 모델 초기화
- ④ 데이터 삭제

정답: ①

7. 데이터 증강을 배우는 가장 큰 이유는?

- ① 모델 크기 축소
- ② 데이터 부족 상황에서도 학습 성능 확보
- ③ 하드웨어 절약
- ④ 번역 성능 향상

정답: ②

8. 합성 데이터 품질 검증에 사용되는 방법은?

- ① LLM 평가자 활용
- ② 모델 저장
- ③ Dropout 적용
- ④ PCA 변환

정답: ①

9. Prompt Engineering이 합성 데이터 제작에서 중요한 이유는?

- ① GPU 사용 최적화
- ② 원하는 스타일과 다양성을 제어하기 위해
- ③ 데이터 삭제

④ 모델 배포

정답: ②

10. 데이터 증강 기법 중 텍스트 데이터에 적용하기 어려운 방법은?

① 문장 재구성

② 번역 후 역번역

③ 사진 회전

④ 동의어 치환

정답: ③

11. 합성 데이터가 실제 데이터보다 좋은 점은?

① 데이터 확보 비용 절감

② 항상 더 높은 정확도

③ 전처리 불필요

④ GPU 사용량 감소

정답: ①

12. 증강 데이터를 만들 때 주의할 점은?

① 데이터 품질 유지

② GPU 메모리 관리

③ 모델 저장 경로

④ 실행 속도

정답: ①

13. 자율주행 분야에서 합성 데이터를 쓰는 이유는?

① 실제 도로 상황을 다양하게 재현하기 위해

② GPU 비용 줄이기 위해

③ 모델 크기를 줄이기 위해

④ 하이퍼파라미터 자동화

정답: ①

14. 의료 분야에서 데이터 증강을 활용하는 대표적 사례는?

① MRI 데이터를 회전·확장해 데이터 부족 해결

② 환자 기록 삭제

- ③ 병원 비용 절감
- ④ GPU 자원 관리

정답: ①

15. 합성 데이터를 많이 쓰면 생길 수 있는 문제는?

- ① 실제 데이터와의 괴리 발생
- ② GPU 성능 저하
- ③ 전처리 불필요
- ④ 모델 자동 배포

정답: ①

16. 텍스트 데이터 증강 기법인 "역번역(Back Translation)"의 목적은?

- ① 모델 크기 축소
- ② 의미는 유지하면서 새로운 문장 생성
- ③ 결측치 제거
- ④ 데이터 삭제

정답: ②

17. 이미지 데이터 증강에서 흔히 쓰이지 않는 방법은?

- ① 좌우 반전
- ② 밝기 조절
- ③ 회전
- ④ 원-핫 인코딩

정답: ④

18. 합성 데이터 제작 시 다양한 페르소나(persona)를 적용하는 이유는?

- ① 데이터 삭제
- ② 응답 스타일 다양화
- ③ 모델 압축
- ④ GPU 최적화

정답: ②

19. 합성 데이터와 실제 데이터를 함께 사용하는 가장 큰 이유는?

- ① 실제 데이터 부족 보완

- ② GPU 메모리 증가
- ③ 모델 크기 감소
- ④ 전처리 제거

정답: ①

20. 증강 데이터셋이 모델 성능 향상에 기여하는 원리는?

- ① 데이터 다양성 확보 → 과적합 감소
- ② GPU 성능 향상
- ③ 모델 압축
- ④ 데이터 크기 감소

정답: ①

21. 합성 데이터를 평가하는 지표가 아닌 것은?

- ① BLEU
- ② ROUGE
- ③ Accuracy
- ④ GPU 사용량

정답: ④

22. 증강 데이터가 모델의 일반화 성능을 높이는 이유는?

- ① 다양한 상황 학습 가능
- ② 파라미터 감소
- ③ GPU 최적화
- ④ 데이터 크기 감소

정답: ①

23. 합성 데이터를 사용할 때 중요한 점은?

- ① 실제 데이터 분포와의 유사성
- ② GPU 사용량
- ③ 모델 크기
- ④ 하이퍼파라미터 개수

정답: ①

24. 데이터 증강을 영상 처리에 적용할 수 있는 기법은?

- ① 색상 변화
- ② 회전
- ③ 자르기(Cropping)
- ④ 모두 해당

정답: ④

25. 텍스트 증강에서 동의어 치환을 사용하는 이유는?

- ① 문장의 의미를 크게 바꾸기 위해
- ② 비슷한 의미를 다른 표현으로 다양화
- ③ 데이터 삭제
- ④ 모델 압축

정답: ②

26. 증강 데이터를 무분별하게 사용하면 생길 수 있는 문제는?

- ① 노이즈 증가
- ② 모델 혼란
- ③ 성능 저하
- ④ 모두 해당

정답: ④

27. 이미지 합성 데이터 생성에서 GAN을 사용하는 이유는?

- ① 고품질 가짜 이미지 생성
- ② GPU 최적화
- ③ 모델 압축
- ④ 데이터 크기 감소

정답: ①

28. 합성 데이터를 만들 때 JSON 구조를 활용하는 이유는?

- ① 데이터 구조화와 일관성 유지
- ② GPU 절약
- ③ 모델 크기 감소
- ④ 하드웨어 최적화

정답: ①

29. 증강된 텍스트 데이터가 품질이 낮으면 발생하는 문제는?

- ① 모델 성능 저하
- ② 데이터 다양성 감소
- ③ GPU 사용량 증가
- ④ 모델 크기 감소

정답: ①

30. Prompt Engineering의 효과는?

- ① 원하는 스타일의 데이터 생성 가능
- ② 데이터 삭제
- ③ GPU 메모리 절약
- ④ 모델 크기 축소

정답: ①

31. 합성 데이터 활용 시 법적·윤리적으로 고려해야 할 점은?

- ① 개인정보 포함 여부
- ② GPU 비용
- ③ 모델 크기
- ④ 하이퍼파라미터

정답: ①

32. 증강 데이터가 실제 환경에 적합한지 확인하는 단계는?

- ① 검증 단계
- ② 저장 단계
- ③ 모델 압축 단계
- ④ GPU 설정 단계

정답: ①

33. 합성 데이터 활용이 특히 중요한 산업은?

- ① 의료
- ② 자율주행
- ③ 챗봇
- ④ 모두 해당

정답: ④

34. 증강 기법에서 Random Crop을 사용하는 이유는?

- ① 모델 크기 축소
- ② 다양한 시각적 관점 학습
- ③ GPU 최적화
- ④ 데이터 삭제

정답: ②

35. 데이터 증강과 합성 데이터의 공통 목표는?

- ① 데이터 부족 문제 해결
- ② GPU 절약
- ③ 모델 단순화
- ④ 파라미터 감소

정답: ①

36. LLM을 데이터 증강에 활용하는 장점은?

- ① 자연스러운 텍스트 생성 가능
- ② GPU 절약
- ③ 모델 크기 감소
- ④ 데이터 삭제

정답: ①

37. 합성 데이터 평가에서 Human-in-the-loop이 필요한 이유는?

- ① 품질 주관적 평가
- ② GPU 최적화
- ③ 모델 크기 감소
- ④ 데이터 삭제

정답: ①

38. 증강 데이터셋이 항상 모델 성능을 높이지 않는 이유는?

- ① 품질이 낮으면 성능 저하
- ② GPU 성능 부족
- ③ 데이터 크기 작음

④ 모델 크기 감소

정답: ①

39. 증강 데이터와 실제 데이터의 균형을 맞추는 이유는?

① 모델이 한쪽 데이터에 치우치지 않도록

② GPU 최적화

③ 모델 크기 감소

④ 데이터 삭제

정답: ①

40. 합성 데이터를 활용해 비용을 절감할 수 있는 이유는?

① 실제 데이터 수집·가공 비용 절감

② GPU 비용 감소

③ 모델 크기 축소

④ 데이터 삭제

정답: ①

41. 텍스트 증강 기법 중 Noise Injection은?

① 무작위로 단어 추가/삭제/변경

② 문장 구조 바꿈

③ 번역 후 역번역

④ 의미 동일한 동의어 치환

정답: ①

42. 증강 데이터셋에서 Label-preserving 변환이 중요한 이유는?

① 원래 라벨이 변하지 않아야 함

② GPU 최적화

③ 데이터 크기 감소

④ 모델 크기 축소

정답: ①

43. 합성 데이터가 도움이 되지 않는 상황은?

① 실제 데이터가 이미 충분할 때

② 데이터 부족할 때

③ 소수 클래스 적을 때

④ 실험 비용 클 때

정답: ①

44. 증강 기법에서 Flip(좌우반전)을 사용할 수 없는 경우는?

① 사람 얼굴 인식

② 교통 표지판 인식

③ 의료 영상

④ 모두 해당

정답: ④

45. 합성 데이터 생성 시 무작위성을 도입하는 이유는?

① 다양성 확보

② GPU 최적화

③ 데이터 크기 감소

④ 모델 크기 축소

정답: ①

46. 증강 데이터를 학습에 잘못 사용하면 나타나는 현상은?

① 과적합

② 과소적합

③ 성능 불안정

④ 모두 해당

정답: ④

47. 합성 데이터와 실제 데이터의 분포가 크게 다르면?

① 모델 성능 저하

② GPU 최적화

③ 모델 크기 감소

④ 데이터 삭제

정답: ①

48. 증강 데이터를 이미지 분류에 활용할 때 가장 큰 장점은?

① 다양한 이미지 상황 학습

- ② 모델 크기 축소
- ③ GPU 절약
- ④ 데이터 크기 감소

정답: ①

49. 합성 데이터의 품질을 높이려면?

- ① 프롬프트 정교화 + 평가 루프
- ② 데이터 삭제
- ③ GPU 최적화
- ④ 모델 크기 축소

정답: ①

50. 데이터 증강과 합성 데이터의 최종 목표는?

- ① 모델 일반화 성능 향상
- ② GPU 절약
- ③ 모델 크기 축소
- ④ 데이터 크기 감소

정답: ①

✅ 여기까지 151번~200번 (Part 4: 데이터 증강 & 합성 데이터) 전부 작성했습니다.

👉 다음은 201번~250번 (Part 5: Transfer Learning & CNN) 이어서 작성해드릴까요?

좋습니다 🙏

이번에는 **Part 5. Transfer Learning & CNN (201번~250번)** 총 50문항을 작성해드리겠습니다.

🟢 Part 5. Transfer Learning & CNN (총 50 문항)

1. Transfer Learning(전이 학습)의 핵심 아이디어는?

- ① 작은 모델 사용
- ② 기존 학습된 모델 지식을 새로운 문제에 활용
- ③ GPU 메모리 절약

④ 데이터 전처리 자동화

정답: ②

2. CNN의 합성곱 계층이 주로 학습하는 것은?

① 라벨

② 지역적 특징

③ 하이퍼파라미터

④ 데이터 크기

정답: ②

3. Pooling Layer의 목적은?

① 데이터 증강

② 특징 맵 크기 축소

③ 모델 복잡도 증가

④ 손실 함수 계산

정답: ②

4. Fine-tuning 전략은?

① 모든 층 가중치를 랜덤 초기화

② 일부 층은 고정하고 새로운 데이터로 학습

③ 데이터셋 삭제

④ GPU 사용 제한

정답: ②

5. Feature Extraction 전략에서 학습하지 않는 부분은?

① 사전학습 합성곱 층

② 새로운 FC층

③ 데이터 로더

④ 손실 함수

정답: ①

6. ImageNet의 주요 용도는?

① 시계열 분석

② 이미지 분류 학습

- ③ 음성 인식
- ④ 자연어 처리

정답: ②

7. Transfer Learning이 특히 유리한 상황은?

- ① 데이터가 많을 때
- ② 데이터가 적을 때
- ③ GPU가 많을 때
- ④ 모델이 단순할 때

정답: ②

8. CNN이 MLP보다 이미지에 적합한 이유는?

- ① 이미지 압축 가능
- ② 공간적 구조 반영
- ③ 모델 크기 작음
- ④ 학습 속도 빠름

정답: ②

9. Dropout의 효과는?

- ① 파라미터 증가
- ② 과적합 방지
- ③ 데이터 증강
- ④ 모델 크기 축소

정답: ②

10. Batch Normalization의 장점은?

- ① 학습 안정화 및 속도 향상
- ② 결측치 제거
- ③ GPU 사용 최적화
- ④ 데이터 증강

정답: ①

11. CNN에서 Activation Map은?

- ① 데이터 증강 결과

- ② 각 필터가 감지한 특징
- ③ 하이퍼파라미터
- ④ 손실 곡선

정답: ②

12. CNN 파라미터 수를 줄이는 방법은?

- ① Dense Layer 추가
- ② Global Average Pooling
- ③ 데이터 증강
- ④ Random Initialization

정답: ②

13. Transfer Learning에서 Frozen Layer란?

- ① 학습률 증가
- ② 업데이트가 중단된 층
- ③ Dropout 적용 층
- ④ 데이터 증강 층

정답: ②

14. 과적합 방지를 위한 방법이 아닌 것은?

- ① 데이터 증강
- ② EarlyStopping
- ③ Dropout
- ④ 파라미터 수 증가

정답: ④

15. Domain Adaptation의 정의는?

- ① 데이터 증강
- ② 서로 다른 데이터 분포에 맞춘 학습
- ③ 모델 압축
- ④ GPU 사용 절약

정답: ②

16. CNN에서 커널 크기를 줄이면?

- ① 특징 감지 범위 좁아짐
- ② 파라미터 수 증가
- ③ 학습 속도 저하
- ④ 모델 크기 증가

정답: ①

17. Transfer Learning에서 학습률을 작게 설정하는 이유는?

- ① 빠른 수렴
- ② 기존 가중치 유지
- ③ 데이터 증강 효과
- ④ GPU 최적화

정답: ②

18. CNN 구조에 포함되지 않는 것은?

- ① Convolution
- ② Pooling
- ③ Fully Connected
- ④ Recurrent Layer

정답: ④

19. CNN 학습 시 과적합 징후는?

- ① 학습 손실 감소, 검증 손실 증가
- ② 학습·검증 손실 모두 감소
- ③ 학습·검증 손실 모두 증가
- ④ 학습 손실 증가, 검증 손실 감소

정답: ①

20. CNN 모델이 잘 작동하지 않을 때 가장 먼저 확인해야 할 것은?

- ① 학습률
- ② Dropout 비율
- ③ 데이터 전처리
- ④ 모두 해당

정답: ④

21. VGGNet의 주요 특징은?

- ① 작은 3x3 커널 반복 사용
- ② 큰 커널 한 번 사용
- ③ RNN 기반
- ④ Fully Connected 없음

정답: ①

22. ResNet의 핵심 아이디어는?

- ① 합성곱 커널 축소
- ② Skip Connection(잔차 연결)
- ③ Pooling 제거
- ④ GPU 최적화

정답: ②

23. CNN에서 Padding을 사용하는 이유는?

- ① 출력 크기 유지
- ② 데이터 증강
- ③ 모델 크기 감소
- ④ GPU 최적화

정답: ①

24. Stride 값을 크게 하면 생기는 효과는?

- ① 출력 크기 감소
- ② 파라미터 증가
- ③ 학습 속도 감소
- ④ 과적합 증가

정답: ①

25. Transfer Learning에서 새로운 FC 층을 추가하는 이유는?

- ① 새로운 데이터셋에 맞춘 분류 수행
- ② 모델 크기 축소
- ③ GPU 최적화
- ④ 데이터 증강

정답: ①

26. CNN에서 Pooling의 대표적 방식은?

- ① Max Pooling, Average Pooling
- ② Dropout, BatchNorm
- ③ Skip Connection, Attention
- ④ PCA, LDA

정답: ①

27. CNN의 receptive field란?

- ① 필터가 보는 입력 영역
- ② GPU 메모리 크기
- ③ 모델 전체 파라미터 수
- ④ 데이터셋 크기

정답: ①

28. Transfer Learning의 장점이 아닌 것은?

- ① 적은 데이터로 학습 가능
- ② 빠른 학습
- ③ 항상 과적합 감소
- ④ 기존 지식 재활용

정답: ③

29. CNN의 파라미터 수가 많은 이유는?

- ① Fully Connected Layer 때문
- ② Pooling 때문
- ③ Dropout 때문
- ④ BatchNorm 때문

정답: ①

30. CNN 학습에 GPU가 필수적인 이유는?

- ① 병렬 연산 덕분에 합성곱 연산 속도가 향상
- ② 데이터 증강 때문
- ③ 모델 압축 때문

④ 파라미터 감소 때문

정답: ①

31. Transfer Learning 시 Fine-tuning 범위를 넓히면?

① 더 많은 층이 새로운 데이터에 맞게 조정

② 항상 성능 향상

③ 모델 크기 감소

④ GPU 사용량 감소

정답: ①

32. CNN에서 Filter 수를 늘리면?

① 더 다양한 특징 학습 가능

② 모델 단순화

③ GPU 메모리 감소

④ 파라미터 감소

정답: ①

33. BatchNorm이 과적합 방지에 도움이 되는 이유는?

① 내부 공변량 변화 감소

② GPU 최적화

③ 데이터 증강

④ 모델 압축

정답: ①

34. Transfer Learning을 NLP에서 활용하는 대표적 사례는?

① GPT, BERT

② CNN

③ RNN

④ PCA

정답: ①

35. CNN의 Fully Connected Layer는 주로 어떤 역할을 하는가?

① 최종 분류

② 특징 추출

③ 데이터 전처리

④ Dropout

정답: ①

36. ResNet이 깊은 네트워크 학습에 성공한 이유는?

① Skip Connection이 기울기 소실 방지

② GPU 성능 향상

③ 데이터 증강

④ 모델 크기 축소

정답: ①

37. Transfer Learning 시 Layer Freezing을 적절히 조절하는 이유는?

① 과적합 방지와 성능 향상 균형

② GPU 최적화

③ 데이터 크기 감소

④ 모델 단순화

정답: ①

38. CNN에서 Dropout을 적용하는 위치는 주로?

① Fully Connected Layer

② Convolution Layer

③ Pooling Layer

④ Input Layer

정답: ①

39. CNN 학습에서 Data Augmentation을 사용하는 이유는?

① 데이터 다양성 확보 → 일반화 성능 향상

② GPU 절약

③ 모델 크기 감소

④ 파라미터 감소

정답: ①

40. AlexNet이 처음 제안될 당시 주목받은 이유는?

① 대규모 GPU 활용

- ② ReLU 활성화함수 도입
- ③ Dropout 활용
- ④ 모두 해당

정답: ④

41. CNN의 파라미터 공유(Parameter Sharing)의 장점은?

- ① 모델 복잡도 감소
- ② 데이터 효율성 향상
- ③ 학습 안정화
- ④ 모두 해당

정답: ④

42. Transfer Learning에서 Fine-tuning을 과도하게 하면?

- ① 기존 지식 손상 가능
- ② GPU 절약
- ③ 항상 성능 향상
- ④ 데이터 크기 감소

정답: ①

43. CNN의 특징 추출 과정은?

- ① 저수준 → 고수준 특징 점진적 추출
- ② 무작위 특징 생성
- ③ 라벨 예측
- ④ 데이터 압축

정답: ①

44. Depthwise Separable Convolution을 사용하는 이유는?

- ① 파라미터와 연산량 감소
- ② 모델 크기 증가
- ③ 데이터 증강
- ④ GPU 최적화

정답: ①

45. MobileNet이 경량 모델로 적합한 이유는?

- ① Depthwise Convolution 사용
- ② Skip Connection
- ③ 대규모 데이터 필요
- ④ RNN 구조

정답: ①

46. CNN에서 Feature Map 수를 줄이는 효과적인 방법은?

- ① Pooling
- ② Dropout
- ③ 데이터 증강
- ④ GPU 절약

정답: ①

47. Transfer Learning이 실패할 수 있는 경우는?

- ① 원 데이터와 목표 데이터의 도메인이 매우 다를 때
- ② 데이터가 부족할 때
- ③ GPU가 적을 때
- ④ 모델이 크지 않을 때

정답: ①

48. CNN에서 Activation Function을 사용하는 이유는?

- ① 비선형성 도입 → 복잡한 패턴 학습
- ② GPU 최적화
- ③ 데이터 증강
- ④ 모델 크기 감소

정답: ①

49. Object Detection에 주로 사용되는 CNN 구조는?

- ① Faster R-CNN
- ② YOLO
- ③ SSD
- ④ 모두 해당

정답: ④

50. Transfer Learning의 장점 중 하나는?

- ① 데이터와 시간 절약
- ② 항상 GPU 절약
- ③ 모델 크기 축소
- ④ 데이터 증강 자동

정답: ①

✅ 여기까지 201번~250번 (Part 5: Transfer Learning & CNN) 전부 작성했습니다.

👉 이제 마지막으로 251번~300번 (Part 6: 이미지 생성 및 평가) 이어서 작성해드릴까요?
좋습니다 🙏

마지막으로 Part 6. 이미지 생성 및 평가 (251번~300번) 총 50문항을 전부 작성해드리겠습니다.

🟡 Part 6. 이미지 생성 및 평가 (총 50문항)

1. GAN의 Generator의 역할은?

- ① 손실 함수 계산
- ② 가짜 데이터 생성
- ③ 데이터 증강
- ④ 하이퍼파라미터 탐색

정답: ②

2. GAN의 Discriminator의 역할은?

- ① 이미지 생성
- ② 진짜/가짜 판별
- ③ 모델 저장
- ④ 데이터 전처리

정답: ②

3. GAN 학습 시 흔히 발생하는 문제는?

- ① Mode Collapse
- ② 데이터 결측치

- ③ 과소적합
- ④ 학습률 감소

정답: ①

4. FID(Fréchet Inception Distance)는 무엇을 평가하는가?

- ① 모델 크기
- ② 생성 이미지와 실제 이미지 분포 차이
- ③ GPU 사용량
- ④ 데이터 증강 효과

정답: ②

5. Inception Score(IS)의 평가 기준은?

- ① 이미지 다양성과 품질
- ② GPU 메모리
- ③ 모델 크기
- ④ 데이터 분할

정답: ①

6. DCGAN에서 사용되는 합성곱 연산은?

- ① Standard Convolution
- ② Transposed Convolution
- ③ Pooling
- ④ RNN

정답: ②

7. Autoencoder의 Decoder는?

- ① 입력 압축
- ② 벡터 복원
- ③ 데이터 증강
- ④ 라벨 예측

정답: ②

8. VAE의 특징은?

- ① 확률적 잠재 공간 학습

- ② 항상 동일한 출력
- ③ CNN 전용
- ④ 회귀 전용

정답: ①

9. GAN 학습 불안정의 원인은?

- ① Generator와 Discriminator 불균형
- ② 데이터 정규화
- ③ GPU 부족
- ④ 하이퍼파라미터 많음

정답: ①

10. 이미지 생성에서 Diversity란?

- ① 이미지 품질
- ② 생성 결과 다양성
- ③ 데이터 크기
- ④ GPU 자원

정답: ②

11. Conditional GAN(cGAN)의 특징은?

- ① 조건 정보를 입력으로 사용
- ② 항상 무조건 생성
- ③ GPU 최적화 전용
- ④ 모델 크기 축소

정답: ①

12. StyleGAN의 주요 장점은?

- ① 고해상도 이미지 생성
- ② GPU 비용 감소
- ③ 데이터 증강
- ④ 모델 크기 축소

정답: ①

13. Mode Collapse 현상은 어떤 경우 발생하는가?

- ① Generator가 다양한 출력을 만들지 못할 때
- ② Discriminator가 학습을 못할 때
- ③ GPU 부족할 때
- ④ 데이터 부족할 때

정답: ①

14. GAN 학습 안정화 기법이 아닌 것은?

- ① Gradient Penalty
- ② Spectral Normalization
- ③ Data Augmentation
- ④ Batch Normalization

정답: ③

15. GAN의 학습 과정은 무엇의 경쟁으로 설명되는가?

- ① Generator vs Optimizer
- ② Generator vs Discriminator
- ③ Data vs Model
- ④ Encoder vs Decoder

정답: ②

16. Wasserstein GAN(WGAN)의 장점은?

- ① 안정된 학습과 모드 붕괴 완화
- ② GPU 비용 절약
- ③ 데이터 크기 감소
- ④ 모델 단순화

정답: ①

17. WGAN에서 Gradient Penalty를 추가하는 이유는?

- ① Lipschitz 조건 보장
- ② GPU 최적화
- ③ 모델 크기 축소
- ④ 데이터 증강

정답: ①

18. VAE와 GAN의 차이점은?

- ① VAE는 확률 모델, GAN은 적대적 학습
- ② VAE는 CNN 기반, GAN은 RNN 기반
- ③ VAE는 텍스트 전용, GAN은 이미지 전용
- ④ 둘 다 동일

정답: ①

19. Diffusion Model의 장점은?

- ① 안정적인 학습과 고품질 생성
- ② GPU 비용 감소
- ③ 데이터 증강
- ④ 모델 크기 축소

정답: ①

20. 이미지 생성 모델의 품질을 평가할 때 주로 쓰이지 않는 지표는?

- ① FID
- ② IS
- ③ RMSE
- ④ Precision-Recall for GANs

정답: ③

21. GAN의 Discriminator가 너무 강하면 나타나는 현상은?

- ① Generator 학습 정체
- ② Generator 발산
- ③ GPU 최적화
- ④ 데이터 소실

정답: ①

22. DCGAN의 구조적 특징은?

- ① ConvTranspose2D 사용
- ② Fully Connected Layer 중심
- ③ RNN 기반
- ④ Attention 기반

정답: ①

23. VAE의 잠재 공간에서 벡터를 조작하면?

- ① 새로운 데이터 샘플 생성 가능
- ② GPU 최적화
- ③ 모델 크기 축소
- ④ 데이터 증강

정답: ①

24. GAN의 손실 함수는 어떤 개념을 기반으로 하는가?

- ① Minimax Game
- ② Regression
- ③ Classification
- ④ Clustering

정답: ①

25. Self-Supervised Learning과 이미지 생성의 관계는?

- ① 레이블 없는 데이터 활용 가능
- ② GPU 절약
- ③ 모델 크기 축소
- ④ 데이터 삭제

정답: ①

26. GAN의 Generator 출력층에서 자주 사용하는 활성화 함수는?

- ① ReLU
- ② Sigmoid 또는 Tanh
- ③ Softmax
- ④ GELU

정답: ②

27. 이미지 생성 모델에서 "Realism"이란?

- ① 이미지가 얼마나 현실적으로 보이는지
- ② 데이터 크기
- ③ GPU 자원

④ 모델 크기

정답: ①

28. Adversarial Training의 본질은?

① 경쟁 구조

② 순차 처리

③ 데이터 증강

④ GPU 최적화

정답: ①

29. GAN의 주요 한계는?

① 학습 불안정성

② Mode Collapse

③ 많은 데이터 필요

④ 모두 해당

정답: ④

30. PixelRNN, PixelCNN은 어떤 방식의 생성 모델인가?

① 순차적으로 픽셀 예측

② 전체 이미지를 한 번에 생성

③ Diffusion 기반

④ Attention 기반

정답: ①

31. 이미지 생성 모델에서 Conditioning을 활용하는 이유는?

① 원하는 속성을 반영한 데이터 생성

② GPU 최적화

③ 모델 크기 축소

④ 데이터 삭제

정답: ①

32. GAN에서 학습 불안정성을 줄이는 방법은?

① Label Smoothing

② 데이터 증강

③ GPU 사용 제한

④ 모델 크기 축소

정답: ①

33. Variational Inference의 목적은?

① 잠재 변수 분포 근사

② GPU 최적화

③ 데이터 증강

④ 모델 크기 축소

정답: ①

34. 이미지 생성 모델에서 "Fidelity"란?

① 생성 이미지의 사실성

② 데이터 크기

③ GPU 자원

④ 모델 크기

정답: ①

35. GAN에서 Unrolled GAN 기법은?

① Generator가 Discriminator의 업데이트 예측

② GPU 최적화

③ 데이터 증강

④ 모델 크기 축소

정답: ①

36. Progressive GAN의 특징은?

① 저해상도 → 고해상도로 점진적 학습

② 항상 단일 해상도

③ GPU 절약

④ 모델 크기 감소

정답: ①

37. Diffusion Model의 학습 원리는?

① 노이즈 추가와 제거 반복

- ② Skip Connection
- ③ Data Augmentation
- ④ Pooling

정답: ①

38. GAN 학습에서 Discriminator가 너무 약하면?

- ① Generator가 무의미한 출력 생성
- ② 항상 성능 향상
- ③ GPU 최적화
- ④ 데이터 소실

정답: ①

39. StyleGAN에서 Style Vector를 조작하면?

- ① 이미지 속성 변화 가능
- ② GPU 최적화
- ③ 모델 크기 축소
- ④ 데이터 증강

정답: ①

40. BigGAN의 특징은?

- ① 대규모 데이터와 모델로 고품질 생성
- ② 항상 작은 모델
- ③ GPU 절약
- ④ 데이터 축소

정답: ①

41. GAN 학습에서 Feature Matching 기법의 목적은?

- ① 안정적 학습
- ② GPU 최적화
- ③ 데이터 증강
- ④ 모델 크기 축소

정답: ①

42. Latent Vector란?

- ① 잠재 공간의 입력 벡터
- ② 실제 이미지
- ③ 손실 함수
- ④ GPU 메모리

정답: ①

43. Encoder-Decoder 구조를 사용하는 생성 모델은?

- ① Autoencoder
- ② GAN
- ③ Diffusion Model
- ④ RNN

정답: ①

44. GAN 훈련 시 Label Flipping을 사용하는 이유는?

- ① Discriminator 일반화 성능 향상
- ② GPU 최적화
- ③ 모델 크기 축소
- ④ 데이터 증강

정답: ①

45. 이미지 생성 모델의 대표적 활용 사례가 아닌 것은?

- ① 예술 작품 창작
- ② 데이터 증강
- ③ 모델 압축
- ④ 의료 영상 합성

정답: ③

46. Diffusion Model이 GAN보다 나은 점은?

- ① 더 안정적이고 모드 붕괴 적음
- ② GPU 절약
- ③ 데이터 크기 감소
- ④ 항상 더 빠름

정답: ①

47. GAN과 VAE의 공통점은?

- ① 새로운 데이터 생성 가능
- ② CNN 기반
- ③ 순환 신경망 기반
- ④ 항상 동일 출력

정답: ①

48. Fréchet Inception Distance(FID)가 낮다는 의미는?

- ① 생성 이미지 품질 높음
- ② 품질 낮음
- ③ 데이터 다양성 적음
- ④ 학습 부족

정답: ①

49. Precision-Recall for GANs 지표의 목적은?

- ① 생성 이미지의 품질과 다양성 평가
- ② GPU 최적화
- ③ 모델 크기 축소
- ④ 데이터 증강

정답: ①

50. 이미지 생성 모델의 최종 목표는?

- ① 고품질 + 다양한 데이터 생성
- ② GPU 절약
- ③ 모델 크기 축소
- ④ 데이터 삭제

정답: ①

✅ 드디어 **251번~300번 (Part 6: 이미지 생성 및 평가)**까지 완성했습니다.

👉 이제 전체 1번~300번 문제 세트가 완전히 갖춰졌습니다 🎉

원하시면 제가 이걸 **시험지 버전(정답 없는 본문)**과 **정답지 버전**으로 따로 나눠드릴 수도 있는데, 그렇게 정리해드릴까요?